Análisis exploratorio de datos, Extracción de Características y Presentación de Resultados

Presentado por: Daniel Guanga

Descripción del Dataset

303

Observaciones Totales

Heart Disease (UCI)

Este conjunto de datos clínico está estructurado con **15 variables** (características predictivas) incluyendo nuestra variable respuesta.

- → **Variable objetivo Y:** target
- → **0:** Paciente sin enfermedad cardíaca confirmada.
- → **1:** Paciente con enfermedad cardíaca presente.

Conclusiones del Resumen Estadístico

- **Rango y dispersión:** Se analizaron métricas fisiológicas clave como la edad, el colesterol, la presión arterial en reposo y la frecuencia cardíaca máxima.
- **Variabilidad en variables de esfuerzo:** La característica 'oldpeak' presenta una alta variabilidad, revelando valores marcadamente altos en ciertos subconjuntos de pacientes.
- **Heterogeneidad útil:** Se evidencia una importante heterogeneidad clínica dentro de los datos, la cual proveerá un excelente terreno para el algoritmo de clasificación.

Conclusiones de Visualizaciones

- **Histograma de edad:** Fuerte concentración poblacional en el segmento de adultos de edad media y adultos mayores.
- **Scatter (thalach vs oldpeak):** Se observa una separación agrupada y parcial de los datos delimitada por la clase objetivo.
- **Boxplot de colesterol por target:** El gráfico confirma la presencia de outliers estadísticos de gran relevancia clínica.

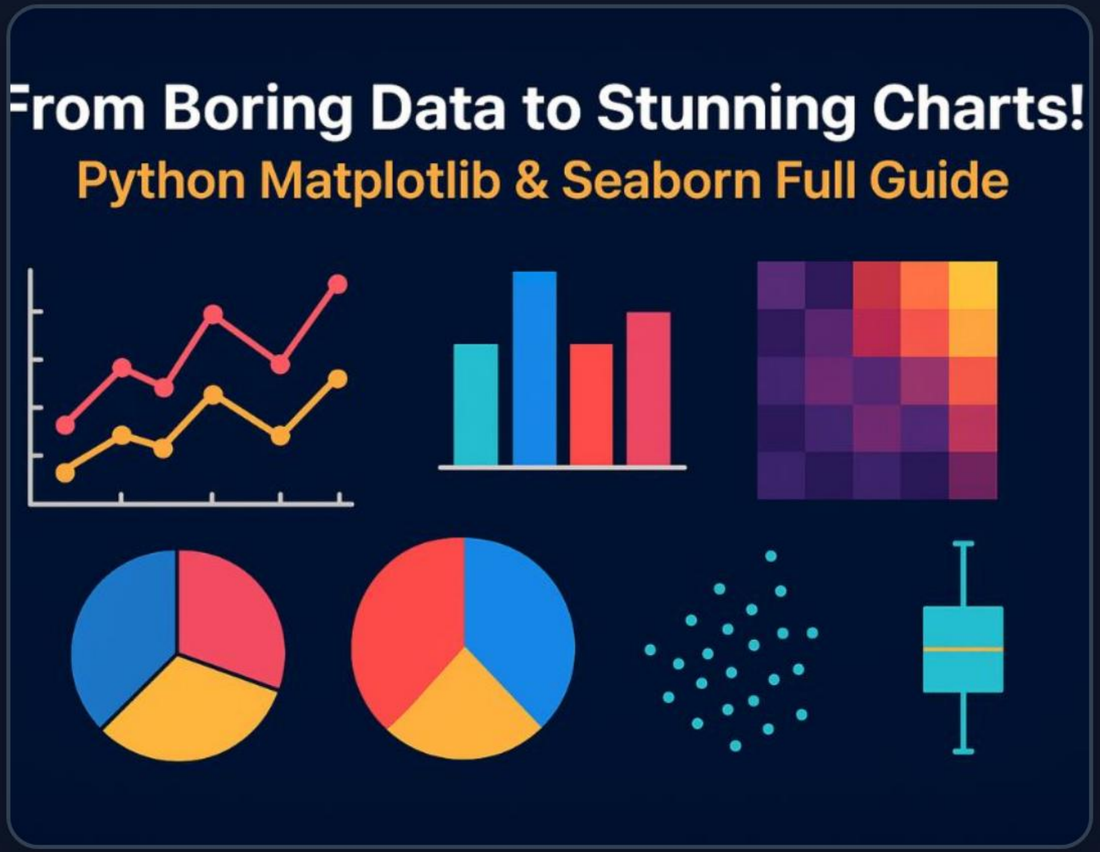

Frecuencias Categóricas

Comportamiento de Clases

Al explorar variables cualitativas, se identificaron claras diferencias proporcionales según las agrupaciones por variables demográficas y clínicas, específicamente: el sexo (**sex**), el tipo de dolor en el pecho (**cp**) y la angina inducida por ejercicio (**exang**).

Discriminación de Riesgo

Las frecuencias indican sólidamente que estas variables categóricas no presentan distribuciones aleatorias; aportan una fuerte **señal estadística** que será vital para discriminar el riesgo de enfermedad cardíaca.

Top 3 Correlaciones con Y

Conclusión: *Estas tres métricas emergen del análisis como las variables candidatas de mayor peso para el modelado predictivo posterior.*

Outliers y Decisión

Detección

Se identificaron sistemáticamente valores atípicos (outliers) en las variables numéricas continuas mediante la técnica del Rango Intercuartílico (IQR).

Decisión

La decisión metodológica sugerida es **no eliminar** automáticamente ninguna de las observaciones etiquetadas como estadísticamente atípicas.

Validación

Dado que tratamos con factores biológicos, es imperativo validar el contexto clínico de estas mediciones extremas antes de filtrar la información.

Hipótesis Iniciales

1. **Frecuencia y Depresión ST:** Una menor frecuencia cardíaca máxima (*thalach*) combinada con un mayor valor de (*oldpeak*) incrementan estructuralmente la probabilidad de que Y=1.

2. **Sintomatología Categórica:** Ciertas categorías específicas de tipo de dolor de pecho (*cp*) y angina inducida (*exang*) conllevan una mayor tasa de enfermedad latente.

3. **Demografía:** Los segmentos de los pacientes de mayor edad en el dataset muestran una prevalencia sustancialmente mayor de casos positivos (Y=1).

Cierre del Análisis

El Análisis Exploratorio de Datos (EDA) desarrollado permite definir de manera asertiva las variables clave y trazar una estrategia formal de preprocesamiento.

Próximo paso: Entrenamiento y comparación de modelos de clasificación.

Image Sources

https://thecypherautomation.com/wp-content/uploads/2025/12/from-boring-data-to-stunning-charts-python-matplotlib-and-seaborn-full-guide.jpg

Source: thecypherautomation.com

---

https://static.vecteezy.com/system/resources/thumbnails/073/907/210/large/abstract-digital-brain-glowing-blue-neural-connections-dark-background-represents-ai-machine-learning-technology-data-intelligence-innovation-science-ideal-for-tech-health-future-concepts-video.jpg

Source: www.vecteezy.com